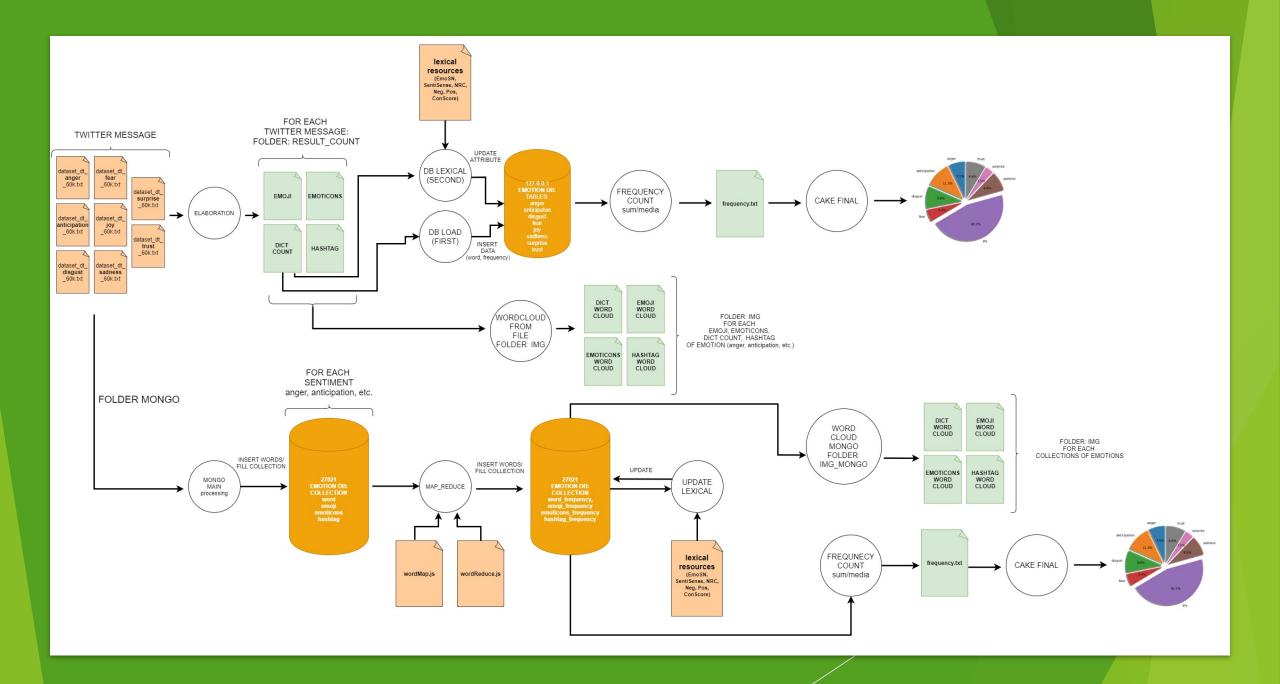
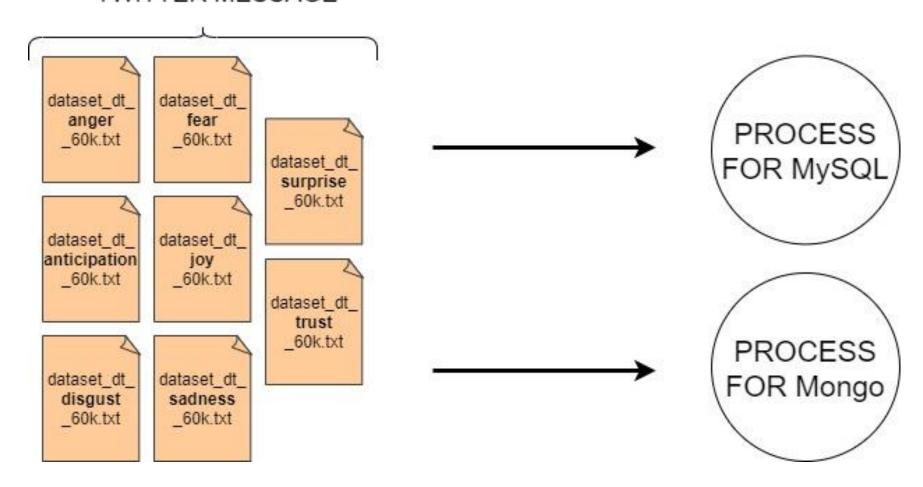
Progetto di Modelli e Architetture Avanzate di DataBase (MAADB)

Bortolotti Simone De Cenzo Davide Marignati Luca

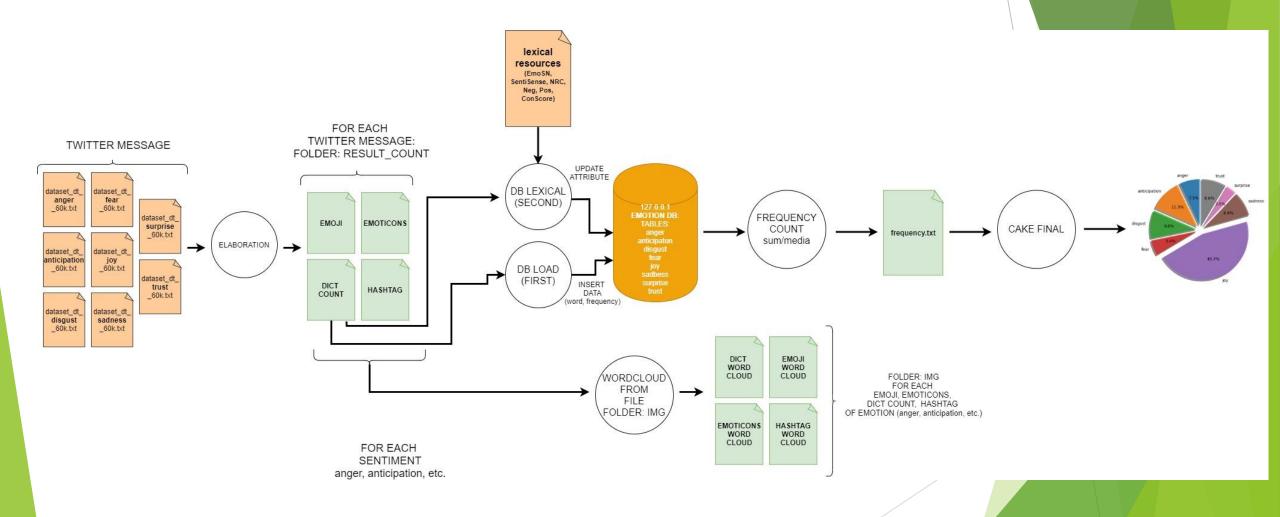




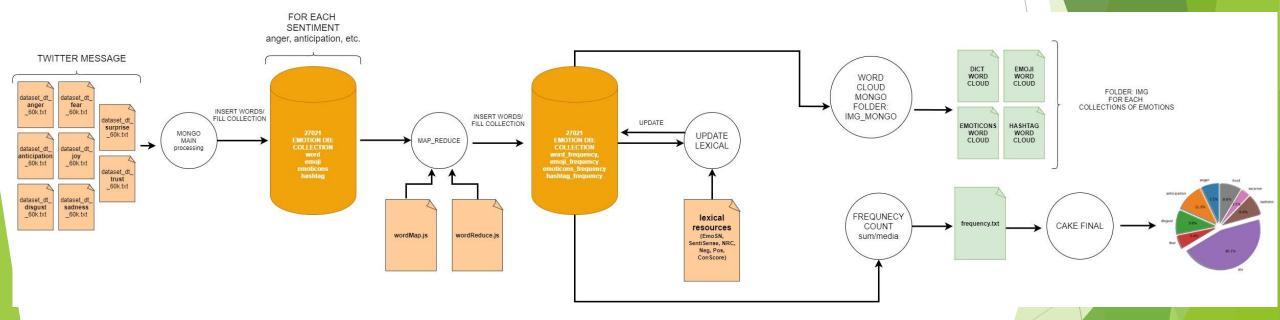
TWITTER MESSAGE



Process for MySQL



Process for Mongo





Main folder

archivi_risorse_lessicali • E.g. Anger, Anticipation, conScore, etc. twitter_message • Initial DATASET (e.g. dataset_dt_anger_60k.txt, etc.) Wordcloud (MySQL) img • 4 for each emotion: word + hashtag + emoji + emoticons wordcloud (Mongo collection) img_mongo • 4 for each emotion: word + hashtag + emoji + emoticons • PRE-LOAD DB: results of ELABORATION.PY (NTLK) result_count • 4 for each emotion: word + hashtag + emoji + emoticons Mongo Mongo elaboration

Main file (1) - MySQL

ELABORATION.PY

- INPUT: twitter message
- processing twitter message (string + nltk operation) + frequency count
- save to local array/dictionary (emoji, emotions, hashtag, word)
- OUTPUT: save local array/dictionary to file into folder «result_count»

DB_LOAD.PY

- INPUT: read file from folder «result_count»
- OUTPUT: insert data to db ("emotion")
- Table = "anger", "anticipation", "disgust", etc.

DB_LEXICAL.PY

- INPUT: read file from folder «lexical resources»
- OUTPUT: Update table ("anger", "anticipation", "disgust", etc.)
- boolean values (emo_sn, ...) + conScore (afinn, ...) + Neg/Pos (gi_neg, ...)

Main file (1) - MySQL

FREQUENCY_COUNT.PY

• INPUT: «select sum from DB»


average calculation

• OUTPUT: save to file «frequency.txt»


WORDCLOUD_FROM_FILE.PY

- INPUT: read result count (e.g anger_emoji.txt, etc.)
- Create wordcloud IMG
- OUTPUT: save file to folder «wordcloud»
- 4 for each emotion: word + hashtag + emoji + emoticons

Elaboration.py (1) - example Processing twitter message



Elaboration.py (2) - example Processing twitter message



pretty legit @ atm the disney gallery

['pretty', 'legit', '@', 'atm', 'the', 'disney', 'galleries']

['pretty', 'legit', '@', 'at the moment', 'the', 'disney', 'galleries ']

[('pretty', 'RB'), ('legit', 'JJ'), ('@', 'NNP'),

('at the moment', 'VBD'), ('the', 'DT'),

('disney', 'NN'), ('galleries ', 'NNS')]


TAG	PART OF SPEECH (POS)	
JJ	adjective	
NNP	proper noun	
VBD	verb, past tense took	
DT	determiner	
NNS	noun, plural	
RB	adverbvery, silently	

['pretty', 'legit', '@', 'at the moment', 'the', 'disney', 'gallery']

Tag	Description	Example	Tag	Description	Example
CC	coordin. conjunction	and, but, or	SYM	symbol	+,%,&
CD	cardinal number	one, two	TO	"to"	10
DT	determiner	a, the	UH	interjection	ah, oops
EX	existential 'there'	there	VB	verb base form	eat
FW	foreign word	mea culpa	VBD	verb past tense	ate
IN	preposition/sub-conj	of, in, by	VBG	verb gerund	eating
JJ	adjective	yellow	VBN	verb past participle	eaten
JJR	adj., comparative	bigger	VBP	verb non-3sg pres	eat
JJS	adj., superlative	wildest	VBZ	verb 3sg pres	eats
LS	list item marker	1, 2, One	WDT	wh-determiner	which, tha
MD	modal	can, should	WP	wh-pronoun	what, who
NN	noun, sing, or mass	llama	WP\$	possessive wh-	whose
NNS	noun, plural	llamas	WRB	wh-adverb	how, when
NNP	proper noun, sing.	IBM	\$	dollar sign	\$
NNPS	proper noun, plural	Carolinas	#	pound sign	#
PDT	predeterminer	all, both	44	left quote	' or "
POS	possessive ending	's	**	right quote	' or "
PRP	personal pronoun	I, you, he	(left parenthesis	[, (, {, <
PRP\$	possessive pronoun	your, one's)	right parenthesis],), }, >
RB	adverb	quickly, never		comma	,
RBR	adverb, comparative	faster	6	sentence-final punc	. ! ?
RBS	adverb, superlative	fastest	:	mid-sentence punc	
RP	particle	up, off		7	

POS TAGGING

Elaboration.py (3) - example Processing twitter message

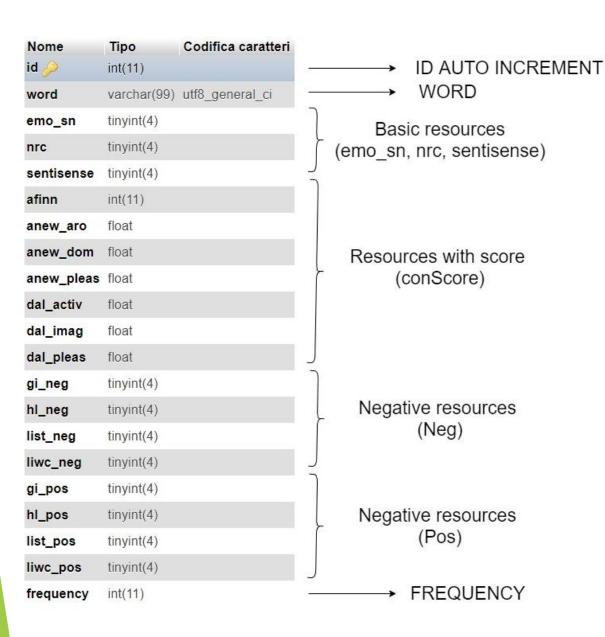




Data structure

```
__mod = modifier_ob__
mirror object to mirror
mirror_object
peration == "MIRROR_X":
irror_mod.use_x = True
irror_mod.use_y = False
operation == "MIRROR_Y"
Irror_mod.use_x = False
"Irror_mod.use_y = True"
lrror_mod.use_z = False
 _operation == "MIRROR_Z"
  rror_mod.use_x = False
  lrror_mod.use_y = False
 lrror_mod.use_z = True
 selection at the end -add
  ob.select= 1
   er ob.select=1
   ntext.scene.objects.action
  "Selected" + str(modified
   irror ob.select = 0
  bpy.context.selected_obje
  ata.objects[one.name].se
 mint("please select exaction
  OPERATOR CLASSES ----
   vpes.Operator):
    X mirror to the selected
   ject.mirror_mirror_x"
 ontext):
oxt.active_object is not
```

MySQL




For each emotion: 8 table

MongoDB

CLUSTER ARCHITECTURE (1)

MONGOS ROUTER

- Router/balancer
- Interfaccia alle applicazioni client;
- Le applicazioni esterne non devono preoccuparsi dell'architettura del sistema, ma possono solamente connettersi a questo nodo come se fosse un semplice database MongoDB;
- Tutte le query e le operazioni di scrittura vengono quindi inviate ai nodi router, che le smistano al cluster.



SHARD 1 (MONGOD)

localhost:27014

SHARD 2 (MONGOD)


localhost:27015 (Luca) localhost:27018 (Davide&Simo) SHARD 3 (MONGOD)

localhost:27016

CLUSTER ARCHITECTURE (2)

CONFIG SERVERS (MONGOD)


- Contiene informazioni sull'architettura del cluster;
- Si occupa della distribuzione, del reperimento dei dati e dello smistamento delle operazioni (a quale nodo inviare le richieste di lettura e di scrittura)
- Nota: per le architetture di produzione, si raccomanda di utilizzarne almeno tre nodi di tipo config servers. Utilizzarne uno solo è infatti un pericolo, perché in caso di guasto tutto il cluster diventa inutilizzabile.




CLUSTER ARCHITECTURE (3)

SHARD (MONGOD)

- nodo di un cluster
- può essere un singolo mongod oppure un Replica Set





SHARD 1 (MONGOD) localhost:27014 SHARD 2 (MONGOD) localhost:27015 (Luca) localhost:27018 (Davide&Simo)

SHARD 3 (MONGOD) localhost:27016

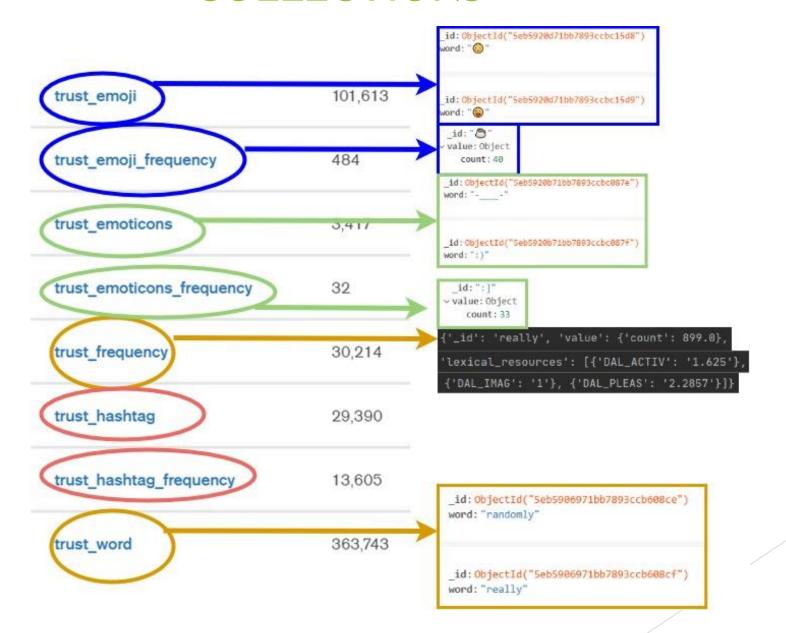
Sharding Data

Example

Collection: trust_word

```
mongos> db.trust word.getShardDistribution()
Shard shard0001 at localhost:27015
 data : 5.55MiB docs : 153289 chunks : 2
 estimated data per chunk : 2.77MiB
 estimated docs per chunk : 76644
Shard shard0002 at localhost:27016
 data : 2.1MiB docs : 57980 chunks : 1
 estimated data per chunk : 2.1MiB
 estimated docs per chunk : 57980
Shard shard0000 at localhost:27014
 data : 5.55MiB docs : 152474 chunks : 2
 estimated data per chunk : 2.77MiB
 estimated docs per chunk : 76237
Totals
 data : 13.2MiB docs : 363743 chunks : 5
 Shard shard0001 contains 42.07% data, 42.14% docs in cluster, avg obj size on shard: 38B
 Shard shard0002 contains 15.9% data, 15.93% docs in cluster, avg obj size on shard : 38B
 Shard shard0000 contains 42.02% data, 41.91% docs in cluster, avg obj size on shard : 38B
```

COLLECTIONS



For each emotion: 8 collection

Document example - word: "Love"

```
'_id': 'love',
'value': {'count': 10677.0},
'lexical_resources': [
     {'GI_POS': 1}, {'HL_POS': 1}, {'LIST_POS': 1}, {'LIWC_POS': 1},
     {'AFINN': '3'}, {'ANEW_ARO': '6.44'},{'ANEW_DOM': '7.11'},{'ANEW_PLEAS': '8.72'},
     {'DAL_ACTIV': '2.6364'}, {'DAL_IMAG': '1.4'}, {'DAL_PLEAS': '3'}
```



MAP REDUCE

map_reduce (1)


```
import pymongo
from bson import Code
client = pymongo.MongoClient("mongodb://localhost:27021/?readPreference=primary&appname=MongoDB%20Compass%20Community"
                             "&ssl=false&retryWrites=false&w=majority")
db = client['emotion']
dataset_sentiment = ["anger", "anticipation", "disgust", "fear", "joy", "sadness", "surprise", "trust"]
for emotion in dataset_sentiment:
   emotion_word = db[emotion + '_word']
   emotion_emoji = db[emotion + '_emoji']
   emotion_emoticons = db[emotion + '_emoticons']
   emotion_hashtag = db[emotion +'_hashtag']
   map = Code(open('wordMap.js', 'r').read())
   reduce = Code(open('wordReduce.js', 'r').read())
   results = emotion_word.map_reduce(map, reduce, emotion + "_frequency")
   emotion_emoji.map_reduce(map, reduce, emotion + "_emoji_frequency")
    emotion_emoticons.map_reduce(map, reduce, emotion + "_emoticons_frequency")
    emotion_hashtag.map_reduce(map, reduce, emotion + "_hashtag_frequency")
```

map_reduce (2) wordMap.js

map_reduce (3) wordReduce.js


```
function wordReduce(key, values){
    var total = 0;
    for (var i = 0; i < values.length; i++){
        total += values[i].count;
    }
    return {count: total};
}</pre>
```

map_reduce (4)



map_reduce (5)

The Overall MapReduce Word Count Process





Statistics of use of lexical resources (MySQL/Mongo)

anger:

6.03 %

anticipation: 9.56 %

disgust:

8.27 %

fear:

4.55 %

joy:

38.74 %

sadness: 7.27 %

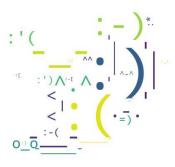
surprise: 2.96 %

trust:

7.30 %

media = 10.58 %

WORDCLOUD



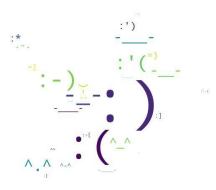






Anger

- EMOTICONS
- EMOJI
- HASHTAG
- WORDS







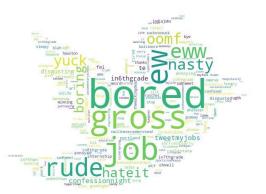


Anticipation

- EMOTICONS
- EMOJI
- HASHTAG
- WORDS



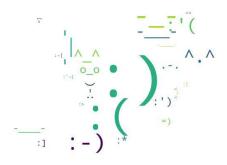






Disgust

- EMOTICONS
- EMOJI
- HASHTAG
- WORDS



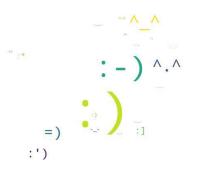






Fear

- EMOTICONS
- EMOJI
- HASHTAG
- WORDS



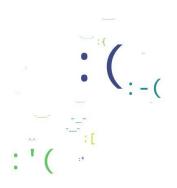






Joy

- EMOTICONS
- **EMOJI**
- HASHTAG
- WORDS







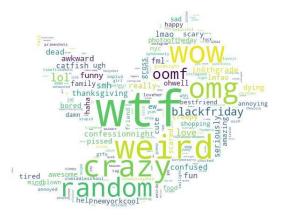


Sadness

- EMOTICONS
- EMOJI
- **HASHTAG**
- WORDS



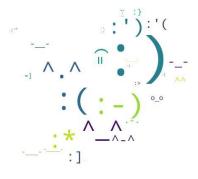






Surprise

- EMOTICONS
- EMOJI
- HASHTAG
- WORDS









Trust

- EMOTICONS
- **EMOJI**
- HASHTAG
- WORDS


Conclusions

Conclusions (1)

PROPERTY	MySQL	MongoDB
Modello dei dati	 Struttura dati fissa; Adatto per una struttura di dati che non cambierà nel tempo; Si creano le tabelle richieste, le colonne e si specifica il tipo di 	 Flessibilità e dinamicità dello schema; Struttura KEY-VALUE; Possibilità di annidamenti (nested); I singoli documenti hanno una propria
	 dati per ogni colonna; Lo schema fisso comporta la presenza di valori NULL; Prima di poter memorizzare i dati, è necessario definire tabelle e colonne. 	struttura, che può essere diversa dagli altri → in ogni momento è possibile creare nuovi campi con un valore qualsiasi.
Ricerca dei dati	 Utilizzo dell'operatore JOIN che permette di combinare dati da più tabelle; Le FOREIGN KEY consentono di creare relazioni tra tabelle; Una ricerca efficace richiede una conoscenza approfondita del modello dei dati di riferimento. 	 Grazie all'annidamento (nested) tutti i dati necessari sono presenti in un solo documento. L'assenza di operazioni di JOIN tra i documenti comporta performance più alte per i tempi di risposta.

Conclusions (2)

PROPERTY	MySQL	MongoDB
Vincoli e integrità dei dati	 Non accetta alcun tipo di dato che non rispetti la strutture imposta dal programmatore. 	 Non esiste un vincolo sul tipo di dato. Svantaggio: non essendoci dei controlli sull'integrità dei dati, il compito ricade totalmente sull'applicativo che dialoga col database.
Scalabilità	 Scalabilità verticale; A fronte di un maggiore carico di lavoro si procede a incrementare l'hardware sulle macchine server; La replica e il clustering sono disponibili, ma comportano complessità implementativa. 	 Scalabilità orizzontale → caratteristica importante per i Big Data; Consente di distribuire i dati e le operazioni su macchine differenti al fine di parallelizzare le operazioni; È possibile configurare più nodi che si replicano automaticamente senza un singolo punto di errore, cosi da evitare che il crash di un server porti all'interruzione del servizio; Elevata scalabilità e disponibilità dei dati.



GRAZIE PER L'ATTENZIONE